

Trayectorias de becarios ANID mediante Grafos de Conocimiento y Procesamiento de Lenguaje Natural: qué produce la inversión pública y cómo se estructura su comunidad científica

Rodrigo Molina Ávila^{1,2} * Sebastián Ferrada Aliaga^{1,2}

¹ Iniciativa de Datos e Inteligencia Artificial, Universidad de Chile

² Instituto Milenio Fundamentos de los Datos (IMFD)

* rodmolina@ug.uchile.cl

Ciencias de la Computación, Ciencia de Datos e Inteligencia Artificial, Políticas Públicas

INTRODUCCIÓN

El Estado chileno expande el desarrollo del capital humano avanzado con de programas que financian la formación doctoral a través la Agencia Nacional de Investigación y Desarrollo (ANID), pero no puede responder dos preguntas básicas: **de qué habla** la ciencia que financia y **cómo se posiciona** la comunidad que la produce.

Los datos existen (ANID, Scopus, Mineduc, Fondecyt), pero están desconectados: sin identificadores comunes ni estructura relacional.

Responder estas preguntas exige modelar **trayectorias**: la secuencia de instituciones, los vínculos de coautoría y las agendas temáticas que definen una carrera.

Chiappa y Pérez Mejías (2019) (de)muestran que la clase social **de origen** opera sobre las trayectorias académicas chilenas por vías directas e indirectas. El grupo socioeconómico (**GSE**) del establecimiento de enseñanza media es el indicador administrativo que permite seguir esa vía a escala de cohorte.

Pregunta de investigación

¿Inciden el género y la clase social de origen en la configuración temática y en la posición estructural de la producción científica de becarios/as ANID?

METODOLOGÍA

Grafo de propiedades:

Siete fuentes federadas en un **property graph** (en Neo4j): 16 tipos de nodo, 15 relaciones y 3,1 M de aristas para **3.143 becarios/as** (2014 a 2016).


Clase social: GSE del establecimiento de enseñanza media.

Topic Modeling y Centralidad:

Se aplicó **BERTopic** sobre 26.071 abstract de publicaciones (SBERT, UMAP, HDBSCAN, c-TF-IDF), con hiperparámetros optimizados mediante **Optuna**: Resultando **237 tópicos**.

Sobre la coautoría intra-cohorte: **Louvain**, **Leiden** validados contra grafos aleatorios Erdős–Rényi; y centralidades (PageRank, betweenness y closeness).

Becarios/as	3.143	Revistas	5.488
Publicaciones	26.071	Fondecyt	1.031
Tópicos	237	Perfil Scopus	86%
Coautores/as	113.221	En la red	496



RESULTADOS

Comunidad Louvain · 21 detectadas	n	%F	B	M	MA	A	Ex	S/D	%Q1
C405 · biología celular	59	37,3	15	36	12	27	2	8	78,5
C449 · síntesis y reacciones	58	34,5	14	24	24	28	2	9	66,4
C478 · genómica del salmón	49	49	20	26	10	26	4	12	80,9
C452 · microbiología	33	48,5	15	54	18	6	0	6	78
C454 · química y parasitología	27	29,6	18	41	15	7	0	18	63,8


Casillas: distribución porcentual del grupo socioeconómico de origen. B bajo · M medio · MA medio alto · A alto · Ex enseñanza media en el extranjero · S/D sin dato. Intensidad proporcional al valor (escala común 0–55%).

A · Paisaje temático y género

Contado sobre becarios/as distintos, el reparto es **asimétrico**: siete tópicos no registran ninguna autora y el máximo femenino llega a 68,0%.


Tópico (términos c-TF-IDF)	n	% F
imaging, contrast, annular	15	0,0
low, neural, energy, neuron	15	0,0
properties, alloys, mechanical	14	0,0
control, systems, stability	11	0,0
optics, adaptive, wavefront	10	0,0
brain, clustering, fibers, white	9	0,0
metallic, molecular, glasses	8	0,0
executive, children, cognitive	25	68
liver, expression, diet, mice	40	67,5
food, recognition, deep learning	9	66,7
cancer, ovarian, epithelial	9	66,7
disease, liver, fatty, nafld	17	64,7
food, scale, satisfaction, life	28	64,3
cancer, gastric, expression	26	61,5

B · Comunidades de coautoría



El componente intra-red de 496 becarios/as se ordena en comunidades densas y temáticamente especializadas. **C452** concentra origen medio (54,5%) y alcanza 78,0% de artículos Q1: la composición social del clúster en su diversidad no anticipa su desempeño editorial.

C · Qué dice la posición estructural



Resultados del rol de puente (Betweenness)	Odds Ratio (OR)	P-value
Volumen de publicaciones (log)	3,35	0,008
Doctorado cursado en Chile	15,96	0,01
Género (mujer, ajustado)	0,87	0,62

A nivel intra-red: **el volumen de producción es la vía identificada**: multiplica por 3,3 la probabilidad del rol de puente, con igual fuerza en cada estrato.

CONCLUSIONES

► La política científica se vuelve interrogable.

Una consulta Cypher recupera: secundaria, pregrado, doctorado (y el prestigio de este a través de rankings), publicaciones, tópicos, campos, coautorías, disciplinas y Fondecyt de los 3.143 becarios/as.

► Respuesta a la pregunta de investigación: incidencia asimétrica.

El género puede configurar la agenda temática, se observan siete tópicos sin autoras, y el máximo para un tópico es de 68%. En la comunidad intra-red ni género ni clase predicen la posición estructural, el volumen de publicaciones y hacer el doctorado en Chile ofrecen mayor centralidad e intermediación.

Próximos pasos: ampliar la cobertura de publicaciones con SciELO y Redalyc, modelar la selección hacia el componente intra-red, estimar la potencia (post-hoc power) para acotar el tamaño de los efectos detectables, alimentar el grafo con los nodos de movilidad institucional y de la información de los conglomerados de las revistas (Springer Nature, Willey, Informa, IEEE, etc.) para entender las características de dónde se destina el conocimiento generado (y la inversión estatal).


► La colaboración de la cohorte se ancla fuera de ella.

El 82,3% de quienes no coautorán con pares mantiene perfil Scopus activo con redes externas: la integración ocurre por vías que exceden el propio grupo.

► Preliminar: Género y clase pierden peso al mirar dentro de cada disciplina.

Ajustando además por disciplina, el género no predice la posición de puente y la asociación es homogénea en todos los estratos de origen. El resultado es preliminar: la muestra acota la brecha por debajo de 9,6 pp. Lo cual es una invitación a explorar lo que sucede dentro de cada una de estas disciplinas (Ciencias Sociales, Naturales, Ingenierías, Agrícolas, Humanidades, Salud).

Explora el grafo



interrogandolaacademia.cl



Interrogando la Academia



rodrigomolinaavila.github.io/gds-becarios



REFERENCIAS

[1] Grootendorst, M. BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv:2203.05794, 2022.

[2] Hogan, A. et al. Knowledge graphs. ACM Computing Surveys, 54(4):1-37, 2021.

[3] Blondel, V. et al. Fast unfolding of communities in large networks. J. Stat. Mech., 2008.

[4] Traag, V. et al. From Louvain to Leiden. Scientific Reports, 9:5233, 2019.

[5] Chiappa, R. y Pérez Mejías, P. Unfolding the direct and indirect effects of social class of origin on faculty income. Higher Education, 78(3):529-555, 2019.

Financiamento: ANID: FONDECYT 11251322 y 11241304. Gracias! ♥